

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО
ОБРАЗОВАНИЯ

Национальный исследовательский ядерный университет «МИФИ»



Институт интеллектуальных кибернетических систем

КАФЕДРА КИБЕРНЕТИКИ

БДЗ

по курсу "Математическая статистика"

студента группы Б23-504

Пономарев Николай

Вариант №14

Оценка: _____

Подпись: _____

2025 г.

ОТЧЕТ № 1

по теме «Проверка статистических гипотез»

Вариант № _____

ФИО студента _____ группа _____

Оценка: _____ Подпись: _____

Результаты статистических тестов:

№ задания	Проверяемая гипотеза H_0	Критерий	Статистическое решение ($\alpha = 0.1$)	Вывод
4.1	$H_0: X \sim N$	Хи-квадрат	H_0 принимается	Гистограмма признака визуально близка к нормальному распределению, нет ошибки статистического решения
4.2	$H_0: X \sim N$	Харке-Бера	H_0 принимается	Гистограмма признака визуально близка к нормальному распределению, выглядит симметрично, нет ошибки статистического решения
5.1	$H_0: F_Y(x) = F_X(x)$	знаков	H_0 отклоняется	Гистограмма признаков визуально выглядит различно для двух выборок, нет ошибки статистического решения
5.2	$H_0: F_Y(x) = F_X(x)$	Хи-квадрат	H_0 отклоняется	Гистограмма признаков визуально выглядит различно для двух выборок, нет ошибки статистического решения

Выводы:

В результате проведённого в п.4 статистического анализа обнаружено, что функция плотности распределения B16 ведет себя как нормальное распределение .

Все тесты сработали корректно, тк мы смогли понаблюдать как ведут себя эти распределения графически .

В результате проведённого в п.5 статистического анализа обнаружено, что Функции плотности распределения B16 и B17 не равны для обоих тестов .

Все тесты сработали корректно, тк мы смогли понаблюдать как ведут себя эти распределения графически .

ОТЧЕТ № 2

по теме «Анализ статистических взаимосвязей»

Вариант № _____

ФИО студента _____ группа _____

Оценка: _____ Подпись: _____

Результаты статистических тестов:

№ задания	Проверяемая гипотеза H_0	Критерий	Статистическое решение ($\alpha = 0.1$)	Вывод
6	$H_0: F_Y(y _{X=x^{(1)}}) = F_Y(y _{X=x^{(2)}})$	Хи-квадрат	H_0 отклоняется	Функции распределения результативного признака при различных значениях факторного признака отличаются
7	$H_0: m_1 = m_2 = m_3$	ANOVA	H_0 отклоняется	Средние значения результативного признака в сравниваемых группах статистически различаются.

Выводы:

В результате проведённого в п.6 статистического анализа обнаружено, что между факторным признаком и результативным признаком существует статистически значимая связь.

В результате проведенного в п.7 статистического анализа обнаружено, что фактор оказывает значимое влияние на результативный признак.

ОТЧЕТ № 3

по теме «Основы регрессионного анализа»

Вариант № _____

ФИО студента _____ группа _____

Оценка: _____ Подпись: _____

Свойство	Простейшая линейная модель	Линейная модель с квадратичным членом	Множественная линейная модель
Точность	неточная	неточная	неточная
Значимость	Значимая	Значимая	Значимая
Адекватность	Адекватная	Адекватная	Адекватная
Степень тесноты связи	слабая	умеренная	умеренная

Выводы:

В результате проведённого в п.8 статистического анализа обнаружено, что между факторным признаком и результативным B16 и B17 существует статистически значимая монотонная зависимость.

В результате проведённого в п.9 статистического анализа обнаружено, что факторный признак B16 оказывает статистически значимое влияние на результативный признак B2

1. Описательные статистики

1.1. Выборочные характеристики

Анализируемый признак 1 – B16

Анализируемый признак 2 – B17

Анализируемый признак 3 – B18

а) Привести формулы расчёта выборочных характеристик

Выборочная хар-ка	Формула расчета
Объём выборки	n

Среднее	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Выборочная дисперсия	$D_X^* = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
Выборочное среднеквадратическое отклонение	$\sigma_X^* = \sqrt{D_X^*} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$
Выборочный коэффициент асимметрии	$\gamma_X^* = \frac{\mu_{3,X}^*}{(\sigma_X^*)^3} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^{\frac{3}{2}}}$
Выборочный эксцесс	$\varepsilon_X^* = \frac{\mu_{4,X}^*}{(\sigma_X^*)^4} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2}$

б) Рассчитать выборочные характеристики

Выборочная хар-ка	Признак 1	Признак 2	Признак 3
Среднее	32.27	28.66	18.23
Выборочная дисперсия	9.09	4.07	0.87
Выборочное среднеквадратическое отклонение	3.02	2.02	0.93
Выборочный коэффициент асимметрии	0.28	-0.22	0.28
Выборочный эксцесс	0.46	0.83	0.36

1.2. Группировка и гистограммы частот

Анализируемый признак – В16 (Biceps circumference (cm))

Объём выборки – 252

а) Выбрать число групп


Число групп	Обоснование выбора числа групп	Ширина интервалов
8	Формула Стерджесса: $k \approx 1 + 1,44\sqrt{n}$	от 2.24 до 2.26

б) Построить таблицу частот

Номер интервала	Нижняя граница	Верхняя граница	Частота	Относит. частота	Накопл. частота	Относит. накопл. частота
1	24.78	27.32	11.0	0.04	11.0	0.04
2	27.32	29.85	41.0	0.16	52.0	0.21
3	29.85	32.38	81.0	0.32	133.0	0.53
4	32.38	34.9	66.0	0.26	199.0	0.79
5	34.9	37.42	44.0	0.17	243.0	0.96

6	37.42	39.95	8.0	0.03	251	1.00
7	39.95	42.48	0	0.00	251	1.00
8	42.48	45.0	1	0.00	252	1.00

в) Построить гистограммы частот и полигоны частот



г) Построить график эмпирической функции распределения



2. Интервальные оценки

2.1. Доверительные интервалы для мат. ожидания

Анализируемый признак – В16 (Biceps circumference (cm))

Объём выборки – 252

Оцениваемый параметр – μ

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$\bar{X} - \frac{S}{\sqrt{n}} \cdot t_{1-\frac{\alpha}{2},(n-1)}$
Верхняя граница	$\bar{X} + \frac{S}{\sqrt{n}} \cdot t_{1-\frac{\alpha}{2},(n-1)}$

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	31.78	31.9	31.96
Верхняя граница	32.77	32.65	32.59

2.2. Доверительные интервалы для дисперсии

Анализируемый признак – В16 (Biceps circumference (cm))

Объём выборки – 252

Оцениваемый параметр – σ^2

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$\frac{(n-1) \cdot S^2}{\chi^2_{1-\frac{\alpha}{2},(n-1)}}$

Верхняя граница	$\frac{(n-1) \cdot S^2}{\chi^2_{\frac{\alpha}{2}, (n-1)}}$
-----------------	--

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	7.33	7.72	7.93
Верхняя граница	11.63	10.96	10.64

2.3. Доверительные интервалы для разности мат. ожиданий

Анализируемый признак 1 – В16 (Abdomen circumference (cm))

Анализируемый признак 2 – В17 (Forearm circumference cm)

Объёмы выборок – $n_1 = n_2 = 252$

Оцениваемый параметр – $m_1 - m_2$

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$(\bar{X}_1 - \bar{X}_2) - t_{1-\frac{\alpha}{2}, (n_1+n_2-2)} \cdot S \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$
Верхняя граница	$(\bar{X}_1 - \bar{X}_2) + t_{1-\frac{\alpha}{2}, (n_1+n_2-2)} \cdot S \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$
S	$\sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}}$

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	3.02	3.16	3.23
Верхняя граница	4.2	4.06	3.99

2.4. Доверительные интервалы для отношения дисперсий

Анализируемый признак 1 – B16 (Abdomen circumference (cm))

Анализируемый признак 2 – B17 (Forearm circumference cm)

Объёмы выборок – $n_1 = n_2 = 252$

Оцениваемый параметр – $\frac{\sigma_1^2}{\sigma_2^2}$

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$\frac{S_1^2}{S_2^2} \cdot F_{\frac{\alpha}{2}, (n_1-1, n_2-1)}$
Верхняя граница	$\frac{S_1^2}{S_2^2} \cdot F_{1-\frac{\alpha}{2}, (n_1-1, n_2-1)}$

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	1.61	1.74	1.82
Верхняя граница	3.1	2.86	2.75

3. Проверка статистических гипотез о математических ожиданиях и дисперсиях

3.1. Проверка статистических гипотез о математических ожиданиях

Анализируемый признак – 'B16' Biceps circumference (cm)

Объём выборки – 252

$$H_0 : m = m_0$$

Статистическая гипотеза – $H' : m \neq m_0$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{\bar{X} - m_0}{\frac{s}{\sqrt{n}}}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$T(n - 1)$
Формулы расчета критических точек	$\pm t_{1-\frac{\alpha}{2}, n-1}$
Формула расчета p -value	$2\min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$

б) Выбрать произвольные значения m_0 и проверить статистические гипотезы

m_0	Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
32	0.1	1.44	0	H_0 принимается	$m = 32$
50	0.1	-93.14	0	H_0 отклоняется	$m \neq 50$
40	0.1	-40.60	0	H_0 отклоняется	$m \neq 40$

3.2. Проверка статистических гипотез о дисперсиях

Анализируемый признак – 'B16' Biceps circumference (cm)

Объём выборки – 252

$$H_0 : \sigma = \sigma_0$$

Статистическая гипотеза – $H' : \sigma \neq \sigma_0$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{(n-1)S^2}{\sigma_0^2}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(n-1)$
Формулы расчета критических точек	$\chi_{\frac{\alpha}{2}, n-1}^2, \chi_{1-\frac{\alpha}{2}, n-1}^2$
Формула расчета p -value	$2\min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$

б) Выбрать произвольные значения σ_0 и проверить статистические гипотезы

σ_0	Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
3	0.1	254.57	0.85	H_0 принимается	$\sigma = 3$
30	0.1	2.55	0	H_0 отклоняется	$\sigma \neq 30$
25	0.1	3.67	0	H_0 отклоняется	$\sigma \neq 25$

3.3. Проверка статистических гипотез о равенстве математических ожиданий

Анализируемый признак 1 – 'B16' Biceps circumference (cm)

Анализируемый признак 2 – 'B17' Forearm circumference (cm)

Объёмы выборок – 252

$$H_0 : m_1 = m_2$$

Статистическая гипотеза – $H' : m_1 \neq m_2$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{\bar{X}_1 - \bar{X}_2}{S \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}, \text{ где } S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$T(n_1 + n_2 - 2)$
Формулы расчета критических точек	$\pm t_{1 - \frac{\alpha}{2}, n_1 + n_2 - 2}$
Формула расчета p -value	$2\min(F_{Z(z_{\text{выб}} H_0}), 1 - F_{Z(z_{\text{выб}} H_0)})$

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	15.76	0.00	H_0 отклоняется	$m_1 \neq m_2$
0.05			H_0 отклоняется	$m_1 \neq m_2$
0.1			H_0 отклоняется	$m_1 \neq m_2$

3.4. Проверка статистических гипотез о равенстве дисперсий

Анализируемый признак 1 – 'B16' Biceps circumference (cm)

Анализируемый признак 2 – 'B17' Forearm circumference (cm)

Объёмы выборок – 252

$$H_0 : \sigma_1 = \sigma_2$$

Статистическая гипотеза – $H' : \sigma_1 \neq \sigma_2$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{s_1^2}{s_2^2}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(n_1 - 1, n_2 - 1)$
Формулы расчета критических точек	$F_{\frac{\alpha}{2}, n_1 - 1, n_2 - 1}, F_{1 - \frac{\alpha}{2}, n_1 - 1, n_2 - 1}$
Формула расчета p -value	$2\min(F_{Z_{\text{выб}}}(z_{\text{выб}} H_0), 1 - F_{Z_{\text{выб}}}(z_{\text{выб}} H_0))$

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	2.27	0.00	H_0 отклоняется	$\sigma_1 \neq \sigma_2$
0.05			H_0 отклоняется	$\sigma_1 \neq \sigma_2$
0.1			H_0 отклоняется	$\sigma_1 \neq \sigma_2$

4. Критерии согласия

Анализируемый признак – 'B16' Biceps circumference (cm)

Объем выборки – 252

4.1. Критерий хи-квадрат

Теоретическое распределение – нормальное.

Статистическая гипотеза – $H_0: X \sim N$ $H_1: X \not\sim N$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \sum_{i=1}^k \frac{(n_i - n \cdot p_i)^2}{n \cdot p_i}$	k - число интервалов в группированном статистическом ряду. n_i - частота попадания случайной величины X в интервал Δ_i . p_i - вероятность попадания случайной величины X в интервал Δ_i в условиях H_0 , то есть, если $\Delta_i = (a_{i-1}, a_i]$, то $p_i = \int_{a_{i-1}}^{a_i} g(x) dx = G(a_i) - G(a_{i-1})$
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(k - r - 1)$	r - количество оцениваемых параметров у предполагаемого распределения G .
Формула расчета критической точки	$\chi^2_{1-\alpha, k-r-1}$	Малые значения Z нам также подходят, поэтому критическая область выбирается правосторонней
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	


б) Выбрать число групп

Число групп	Обоснование выбора числа групп	Ширина интервалов
8	Формула Стерджесса: $k \approx 1 + 1,44\ln n$ $n \cdot p_i \geq 5$ - поправка на чувствительность критерия	От 1.23 до 1027.33

в) Построить таблицу частот

Номер интервала	Нижняя граница	Верхняя граница	Частота	Относит. частота	Вероятность попадания в интервал при условии истинности основной гипотезы
1	21	27	8	0.031746	0.050726
2	27	28.5	14	0.055556	0.160517
3	28.50	29.25	14	0.055556	0.142327
4	29.25	30.00	19	0.075397	0.159841
5	30.00	31.50	51	0.202381	0.157051
6	31.5	33.00	48	0.190476	0.137214
7	33.00	36.00	67	0.265873	0.148236
8	36.00	45.00	30	0.119048	0.044087

г) Построить гистограмму относительных частот и функцию плотности теоретического распределения на одном графике



д) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	7.34	0.20	H_0 принимается	$X \sim N$
0.05	7.34	0.20	H_0 принимается	$X \sim N$
0.1	7.34	0.20	H_0 принимается	$X \sim N$

4.2. Проверка гипотезы о нормальности на основе коэффициента асимметрии и эксцесса (критерий Харке-Бера)

Статистическая гипотеза – $H_0: X \sim N$ $H_1: X \not\sim N$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = Z_1^2 + Z_2^2, \text{ где}$ $Z_1 = \frac{\gamma_X^*}{\sqrt{\frac{6}{n}}},$ $Z_2 = \frac{\epsilon_X^*}{\sqrt{\frac{24}{n}}}$	γ_X^* - выборочный коэффициент асимметрии. ϵ_X^* - выборочный эксцесс. n - объём выборки.
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(2)$	2 степени свободы
Формула расчета критической точки	$\chi_{1-\alpha,2}^2$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	Правосторонняя критическая область

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	5.65	0.06	H_0 отклоняется	$X \not\sim N$

0.05			H_0 принимается	$X \sim N$
0.1			H_0 принимается	$X \sim N$

Вывод (в терминах предметной области)

В результате проведённого в п.4 статистического анализа обнаружено, что критерий χ^2 не отвергает гипотезу о нормальности распределения и критерий Харке-Бера не отвергает её. Только при уровне значимости 0.1 гипотеза о нормальном распределении отвергалась. Это означает, что при более точной оценке выявляется отклонение от нормального распределения.

5. Проверка однородности выборок

Анализируемый признак 1 – 'B16' Biceps circumference (cm)

Анализируемый признак 2 – 'B17' Forearm circumference (cm)

Объёмы выборок – 252

5.1 Критерий знаков

Статистическая гипотеза – $H_0: F_X(x) = F_Y(x) \quad H: F_X(x) \neq F_Y(x)$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{K_+ - \frac{n}{2}}{\frac{\sqrt{n}}{2}}$	K_+ - число знаков '+' в выборке $z_1, \dots, z_n = x_1 - y_1, \dots, x_n - y_n$
Закон распределения статистики критерия при условии истинности основной гипотезы	$N(0, 1)$	
Формула расчета критической точки	$\pm u_{1-\frac{\alpha}{2}}$	
Формула расчета p -value	$2\min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$	Двусторонняя критическая область

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	15.24	0.00	H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.05			H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.1			H_0 отклоняется	$F_X(x) \neq F_Y(x)$

5.2. Критерий хи-квадрат

Статистическая гипотеза – $H_0: F_X(x) = F_Y(x)$ $H': F_X(x) \neq F_Y(x)$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = nm \sum_{i=1}^k \frac{1}{n_i + m_i} \left(\frac{n_i}{n} + \frac{m_i}{m} \right)$	k - число интервалов в группированном статистическом ряду. n_i - частота попадания случайной величины X в интервал Δ_i. m_i - частота попадания случайной величины Y в интервал Δ_i. n - объём выборки $x_1, \dots, x_n$ m - объём выборки $y_1, \dots, y_m$
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(k - 1)$	$k-1$ число степеней свободы
Формула расчета критической точки	$\chi_{1-\alpha, k-1}^2$	
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	Правосторонняя критическая область

б) Выбрать число групп


Число групп	Обоснование выбора числа групп	Ширина интервалов
8	$k \approx 1 + 1.44 \ln(\max(n, m))$ - формула Стерджесса $n_i + m_i \gtrsim 5$ - поправка на чувствительность критерия	Ширина интервалов: от 0.75 до 9.00

в) Построить таблицу частот

Номер интервала	Нижняя граница	Верхняя граница	Частота признака 1	Частота признака 2	Относит. частота признака 1	Относит. частота признака 2
1	21.00	27.00	8.0	47.0	0.031746	0.186508
2	27.00	28.50	14.0	68.0	0.055556	0.269841

3	28.50	29.25	14.0	34.0	0.055556	0.134921
4	29.25	30.00	19.0	36.0	0.075397	0.142857
5	30.00	31.50	51.0	48.0	0.202381	0.190476
6	31.50	33.00	48.0	15.0	0.190476	0.059524
7	33.00	36.00	67.0	4.0	0.265873	0.015873
8	36.00	45.00	31.0	0.0	0.123016	0.000000

г) Построить гистограммы относительных частот на одном графике



д) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	181.08	0.00	H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.05			H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.1			H_0 отклоняется	$F_X(x) \neq F_Y(x)$

Вывод (в терминах предметной области)

В результате проведённого в п.5 статистического анализа обнаружено, что выборки В16 и В17 неоднородны.

6. Таблицы сопряжённости

Факторный признак x – В3 (Body fat)

Результативный признак y – В5 (Sex)

Объёмы выборок – $n_1 = n_2 = n = 252$

Статистическая гипотеза –

$$H_0: F_Y(y|_{X=x^{(1)}}) = F_Y(y|_{X=x^{(2)}}) = \dots = F_Y(y|_{X=x^{(k_1)}}) = F_Y(y) \quad H': \exists i, j: F_Y(y|_{X=x^{(i)}}) \neq F_Y(y|_{X=x^{(j)}})$$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \sum_{i=1}^{k_1} \sum_{j=1}^{k_2} \frac{(n_{ij} - m_{ij})^2}{m_{ij}}$	$(x_1, y_1), \dots, (x_n, y_n)$ - наблюдения случайного вектора (X, Y) , где X, Y - случайные величины дискретного типа $x^{(1)}, \dots, x^{(k_1)}$ - варианты признака X $y^{(1)}, \dots, y^{(k_2)}$ - варианты признака Y n_{ij} - выборочная частота варианта $(x^{(i)}, y^{(j)})$ в выборке $(x_1, y_1), \dots, (x_n, y_n)$ m_{ij} - теоретическая частота варианта $(x^{(i)}, y^{(j)})$ в выборке $(x_1, y_1), \dots, (x_n, y_n)$ при условии истинности H_0
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2((k_1 - 1)(k_2 - 1))$	
Формула расчета критической точки	$\chi^2_{1-\alpha, (k_1-1)(k_2-1)}$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	

б) Построить эмпирическую таблицу сопряжённости

Вариант Y Вариант X	$y^{(1)}$	$y^{(2)}$	Σ
$x^{(1)}$	65	55	120

$x^{(2)}$	8	31	39
$x^{(3)}$	20	73	93
Σ	93	159	252

в) Построить теоретическую таблицу сопряжённости

Вариант Y Вариант X	$y^{(1)}$	$y^{(2)}$	Σ
$x^{(1)}$	44,29	75,71	120
$x^{(2)}$	14,39	24,61	39
$x^{(3)}$	34,32	58,68	93
Σ	93	159	252

г) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	29.33	0.00	H_0 отклоняется	$\exists i, j: F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$
0.05			H_0 отклоняется	$\exists i, j: F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$
0.1			H_0 отклоняется	$\exists i, j: F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$

Вывод (в терминах предметной области)

В результате проведённого в п.6 статистического анализа обнаружено, что факторным признаком В3 и результативным признаком В5 присутствует статистическая связь. Под действием В3 оказывается влияние на распределение В5.

7. Дисперсионный анализ

Факторный признак x – 'B3' Body fat

Результативный признак y – 'B16' Biceps circumference (cm)

Число вариантов факторного признака – 3

Объёмы выборок – $n_1 = n_2 = n = 252$

Статистическая гипотеза –

$$H_0: F_Y(y|_{X=x_1}) = F_Y(y|_{X=x_2}) = \dots = F_Y(y|_{X=x_k}) = F_Y(y) \quad H': \exists i, j: F_Y(y|_{X=x_i}) \neq F_Y(y|_{X=x_j})$$

а) Рассчитать групповые выборочные характеристики

№ п/п	Вариант факторного признака	Объём выборки	Групповые средние	Групповые дисперсии
1	high	120	33.515833	7.185666
2	low	39	30.238462	7.926982
3	normal	93	31.523656	7.749548

б) Привести формулы расчёта показателей вариации, используемых в дисперсионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\tilde{D}_{\text{межгр}} = \frac{1}{n} \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2$	$k - 1$	$\frac{n}{k-1} \tilde{D}_{\text{межгр}}$
Остаточные признаки	$\tilde{D}_{\text{внутр}} = \frac{1}{n} \sum_{i=1}^k n_i \sigma_i^2$, где $\sigma_i^2 = \frac{1}{n_i} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$ — групповая дисперсия	$n - k$	$\frac{n}{n-k} \tilde{D}_{\text{внутр}}$
Все признаки	$\tilde{D}_{\text{общ}} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2$	$n - 1$	$\frac{n}{n-1} \tilde{D}_{\text{общ}}$

в) Рассчитать показатели вариации, используемые в дисперсионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\tilde{D}_{\text{межгр}} = 1.58$	$k - 1 = 2$	$\frac{n}{k-1} \tilde{D}_{\text{межгр}} = 199.51$
Остаточные признаки	$\tilde{D}_{\text{внутр}} = 7.51$	$n - k = 249$	$\frac{n}{n-k} \tilde{D}_{\text{внутр}} = 7.60$
Все признаки	$\tilde{D}_{\text{общ}} = 9.09$	$n - 1 = 251$	$\frac{n}{n-1} \tilde{D}_{\text{общ}} = 9.13$

г) Проверить правило сложения дисперсий

Показатель	$D_{\text{межгр}}$	$D_{\text{внутригр}}$	$D_{\text{общ}}$	$D_{\text{межгр}} + D_{\text{внутригр}}$
Значение	1.58	7.51	9.09	9.09

д) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Эмпирический коэффициент детерминации	$\eta^2 = \frac{\bar{D}_{\text{межгр}}}{\bar{D}_{\text{общ}}}$	0.17
Эмпирическое корреляционное отношение	$\eta = \sqrt{\eta^2} = \sqrt{\frac{\bar{D}_{\text{межгр}}}{\bar{D}_{\text{общ}}}}$	0.42

е) Охарактеризовать тип связи между факторным и результативным признаками

По шкале Чеддока наблюдается умеренная связь между факторным В3 и В16 результативным признаком

ж) Указать формулы расчёта показателей, используемых при проверке статистической гипотезы дисперсионного анализа

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{n-k}{k-1} \frac{\bar{D}_{\text{межгр}}}{\bar{D}_{\text{внутр}}}$	k — число групп n — объём выборки $y_1, \dots, y_n$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(k-1, n-k)$	
Формула расчета критической точки	$F_{1-\alpha, k-1, n-k}$	
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	Правосторонняя критическая область

з) Проверить статистическую гипотезу дисперсионного анализа

Уровень значимости	Выборочное значение статистики критерия	$p\text{-value}$	Статистическое решение	Вывод
0.01	26.25	0.00	H_0 отклоняется	$\exists i, j F_Y(y _{X=x_i}) \neq F_Y(y _{X=x_j})$
0.05			H_0 отклоняется	$\exists i, j F_Y(y _{X=x_i}) \neq F_Y(y _{X=x_j})$
0.1			H_0 отклоняется	$\exists i, j F_Y(y _{X=x_i}) \neq F_Y(y _{X=x_j})$

Вывод (в терминах предметной области)

В результате проведённого в п.7 статистического анализа установлено, что между факторным признаком В3 и результативным признаком В16 существует статистически значимая связь.

Для всех рассмотренных уровней значимости нулевая гипотеза о равенстве распределений признака В16 во всех группах В3 отвергается. Это означает, что факторный признак В3 оказывает влияние на распределение результативного признака В16: по крайней мере две группы значимо различаются между собой.

8. Корреляционный анализ

8.1. Расчёт парных коэффициентов корреляции

Анализируемый признак 1 – 'B16' Biceps circumference (cm)

Анализируемый признак 2 – 'B17' Forearm circumference (cm)

Объёмы выборок – 252

а) Рассчитать точечные оценки коэффициентов корреляции

	Формула расчёта	Значение
Линейный коэффициент корреляции	$\tilde{\rho}_{XY} = \frac{\text{cov}(X,Y)}{\sigma_X \cdot \sigma_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$	0.68
Ранговый коэффициент корреляции по Спирмену	$\tilde{\rho}_{XY}^{(sp)} = \rho_{RS}$, где R и S — ранги для выборок X и Y соответственно. Можно показать, что $\tilde{\rho}_{XY}^{(sp)} = 1 - \frac{6S}{n(n^2-1)}$, где $S = \sum_{i=1}^n (r_i - s_i)^2$	0.76
Ранговый коэффициент корреляции по Кендаллу	$\tau_{XY} = \frac{N_+ - N_-}{n(n-1)/2}$, где N_+, N_- — количество пар точек (x_i, y_i) таких, что $(x_i - x_j)(y_i - y_j) > 0, (x_i - x_j)(y_i - y_j) < 0$ соответственно. Другой вариант расчёта: $\tau_{XY} = \frac{4R}{n(n-1)} - 1$, где $R = \sum_{i=1}^n \sum_{j=i+1}^n 1[s_j > s_i]$ — число инверсий в выборке $(r_1, s_1), \dots, (r_n, s_n)$, предварительно отсортированной по возрастанию r_i .	0.60

б) Привести формулы расчёта доверительного интервала для линейного коэффициента корреляции

Для объёмов выборок: $n < 500$

Граница доверительного интервала	Формула расчёта
Нижняя граница	$th\left(\frac{1}{2} \ln \frac{1+\tilde{\rho}}{1-\tilde{\rho}} + \frac{\tilde{\rho}}{2(n-1)} - \frac{u_{1-\frac{\alpha}{2}}}{\sqrt{n-3}}\right)$
Верхняя граница	$th\left(\frac{1}{2} \ln \frac{1+\tilde{\rho}}{1-\tilde{\rho}} + \frac{\tilde{\rho}}{2(n-1)} + \frac{u_{1-\frac{\alpha}{2}}}{\sqrt{n-3}}\right)$

в) Рассчитать доверительные интервалы для линейного коэффициента корреляции

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	0.58	0.606	0.618
Верхняя граница	0.757	0.740	0.73

г) Указать формулы расчёта показателей, используемых при проверке значимости коэффициентов корреляции

Статистическая гипотеза	Формула расчета статистики критерия	Закон распределения статистики критерия при условии истинности основной гипотезы
$H_0: \rho = 0$ $H': \rho \neq 0$	$Z = \frac{\rho_{XY} \cdot \sqrt{n-2}}{\sqrt{1-\rho_{XY}^2}}$	$T(n-2)$
$H_0: r^{(cn)} = 0$ $H': r^{(cn)} \neq 0$	$Z = \frac{\rho_{XY}^{(sp)} \cdot \sqrt{n-2}}{\sqrt{1-(\rho_{XY}^{(sp)})^2}}$	$T(n-2)$
$H_0: r^{(кен)} = 0$ $H': r^{(кен)} \neq 0$	$\sqrt{\frac{9n(n+1)}{2(2n+5)}} \cdot \tau_{XY}$	$N(0, 1)$

д) Проверить значимость коэффициентов корреляции

Статистическая гипотеза	Уровень значимости	Выборочное значение статистики критерия	p-value	Статистическое решение	Вывод
$H_0: \rho = 0$ $H': \rho \neq 0$	0.1	14.59	0	H_0 отклоняется	$\rho_{XY} \neq 0$
$H_0: r^{(cn)} = 0$ $H': r^{(cn)} \neq 0$	0.1	18.66	0	H_0 отклоняется	$\rho_{XY}^{(sp)} \neq 0$
$H_0: r^{(кен)} = 0$ $H': r^{(кен)} \neq 0$	0.1	14.13	0	H_0 отклоняется	$\tau_{XY} \neq 0$

8.2. Расчёт множественных коэффициентов корреляции

Анализируемый признак 1 – 'B16' Biceps circumference (cm)
 Анализируемый признак 2 – 'B17' Forearm circumference (cm)
 Анализируемый признак 3 – 'B18' Wrist circumference (cm)
 Объёмы выборки – 252

а) Рассчитать матрицу ранговых коэффициентов корреляции по Кендаллу

Признак \ Признак	B16	B17	B18
B16	1.00	0.602929	0.435948
B17	0.602929	1.00	0.490008
B18	0.435948	0.490008	1.00

б) Рассчитать матрицу значений p -value для ранговых коэффициентов корреляции по Кендаллу (статистическая гипотеза $H_0: \tau = 0$ $H': \tau \neq 0$)

Признак \ Признак	B16	B17	B18
B16	–	3.750373e-45	5.444522e-24
B17	3.750373e-45	–	9.860756e-30
B18	5.444522e-24	9.860756e-30	–

в) Рассчитать точечную оценку коэффициента конкордации

	Формула расчета	Значение
Коэффициент конкордации	$\tilde{W} = \frac{12}{k^2(n^3 - n)} \cdot \sum_{i=1}^n \left(\sum_{j=1}^k r_{ij} - \frac{k(n+1)}{2} \right)^2$, где r_{ij} — ранг i-ого объекта в j-ой выборке. k — количество выборок. n — объём выборок.	0.78

г) Указать формулы расчёта показателей, используемых при проверке значимости коэффициента конкордации

Статистический критерий: $H_0: W = 0$ $H': W \neq 0$

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = n(k - 1)W^{\sim}$	$W^{\sim}$ — точечная оценка коэффициента конкордации. k — количество выборок. n — объём каждой выборки.
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(n - 1)$	
Формула расчета критической точки	$\chi^2_{1-\alpha, n-1}$	
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	Правосторонняя критическая область

д) Проверить значимость коэффициента конкордации

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	392.41	0.00	H_0 отклоняется	$W \neq 0$
0.05			H_0 отклоняется	$W \neq 0$
0.1			H_0 отклоняется	$W \neq 0$

Вывод (в терминах предметной области)

В результате проведённого в п.8 статистического анализа обнаружено, что между признаками В16 и В17 наблюдается сильная положительная связь, в первую очередь монотонная связь, также присутствует линейная связь. Между признаками В16, В17 и В18 также наблюдается достаточно высокая согласованность рангов.

9. Регрессионный анализ

9.1 Простейшая линейная регрессионная модель

Факторный признак x – `B16` Biceps circumference (cm)

Результативный признак y – `B2` (Percent body fat from Siri's equation)

Уравнение регрессии – $f(x) = \beta_0 + \beta_1 x$

9.1.1. Точечные оценки линейной регрессионной модели

а) Рассчитать точечные оценки параметров линейной регрессионной модели

Параметр	Формула расчета	Значение
β_0	$\bar{y} - \rho_{XY} \cdot \frac{\tilde{\sigma}_Y}{\tilde{\sigma}_X} \cdot \bar{x}$	-24.95
β_1	$\rho_{XY} \cdot \frac{\tilde{\sigma}_Y}{\tilde{\sigma}_X}$	1.37

б) Записать точечную оценку уравнения регрессии

$$f(x) = -24.95 - 1.37x$$

в) Привести формулы расчёта показателей вариации, используемых в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\tilde{D}_{Y X} = \frac{1}{n} \sum_{i=1}^n (\tilde{f}(x_i) - \bar{y})^2$	$k - 1$	$\frac{n}{k-1} \tilde{D}_{Y X}$
Остаточные признаки	$\tilde{D}_{Y_{\text{ост}}} = \frac{1}{n} \sum_{i=1}^n (\tilde{f}(x_i) - y_i)^2$	$n - k$	$\frac{n}{n-k} \tilde{D}_{Y_{\text{ост}}}$
Все признаки	$\tilde{D}_{Y_{\text{общ}}} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$	$n - 1$	$\frac{n}{n-1} \tilde{D}_{Y_{\text{общ}}}$

k — число оцениваемых параметров функции регрессии $f(x)$.

г) Рассчитать показатели вариации, используемые в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\tilde{D}_{Y X} = 16.97$	$k - 1 = 1$	$\frac{n}{k-1} \tilde{D}_{Y X} = 4277.26$
Остаточные признаки	$\tilde{D}_{Y_{ост}} = 52.78$	$n - k = 250$	$\frac{n}{n-k} \tilde{D}_{Y_{ост}} = 53.21$
Все признаки	$\tilde{D}_{Y_{общ}} = 69.76$	$n - 1 = 251$	$\frac{n}{n-1} \tilde{D}_{Y_{общ}} = 70.04$

д) Проверить правило сложения дисперсий

Показатель	$D_{факт}$	$D_{ост}$	$D_{общ}$	$D_{факт} + D_{ост}$
Значение	16.97	52.78	69.76	69.76

е) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Коэффициент детерминации	$R^2 = \frac{\tilde{D}_{Y X}}{\tilde{D}_{Y_{общ}}}$	0.24
Корреляционное отношение	$\tilde{R} = \sqrt{R^2} = \sqrt{\frac{\tilde{D}_{Y X}}{\tilde{D}_{Y_{общ}}}}$	0.49

ж) Охарактеризовать тип связи между факторным и результативным признаками, определяемой рассчитанной линейной регрессией

Наблюдается умеренная корреляционная связь между факторным признаком В16 и результативным признаком В2.

9.1.2. Интервальные оценки линейной регрессионной модели

а) Привести формулы расчёта доверительных интервалов для параметров линейной регрессионной модели

Параметр	Границы доверительного интервала	Формула расчета
β_0	Нижняя граница	$\tilde{\beta}_0 - t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{D_{Y_{\text{ост}}}^{\sim\text{несмещ}}} \cdot \sqrt{\frac{\sum_{i=1}^n x_i^2}{n^2 D_x}}$
	Верхняя граница	$\tilde{\beta}_0 + t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{D_{Y_{\text{ост}}}^{\sim\text{несмещ}}} \cdot \sqrt{\frac{\sum_{i=1}^n x_i^2}{n^2 D_x}}$
β_1	Нижняя граница	$\tilde{\beta}_1 - t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{D_{Y_{\text{ост}}}^{\sim\text{несмещ}}} \cdot \sqrt{\frac{1}{n D_x}}$
	Верхняя граница	$\tilde{\beta}_1 + t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{D_{Y_{\text{ост}}}^{\sim\text{несмещ}}} \cdot \sqrt{\frac{1}{n D_x}}$


б) Рассчитать доверительные интервалы для параметров линейной регрессионной модели

Параметр	Границы доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
β_0	Нижняя граница	-37.766688	-34.673828	-33.100442
	Верхняя граница	-12.124011	-15.216870	-16.790257
β_1	Нижняя граница	0.970780	1.066198	1.114738
	Верхняя граница	1.761880	1.666463	1.617922


в) Привести формулы расчёта доверительного интервала для значений регрессии $f(x)$

Границы доверительного интервала	Формула расчета
Нижняя граница $f_{low}(x)$	$(\tilde{\beta}_0 + \tilde{\beta}_1 x) - t_{1-\frac{\alpha}{2}, (n-2)} \cdot \sqrt{D_{Y_{ост}}^{\text{несмещ}}} \cdot \sqrt{\frac{1}{n} + \frac{(x-\bar{x})^2}{nD_x}}$
Верхняя граница $f_{high}(x)$	$(\tilde{\beta}_0 + \tilde{\beta}_1 x) + t_{1-\frac{\alpha}{2}, (n-2)} \cdot \sqrt{D_{Y_{ост}}^{\text{несмещ}}} \cdot \sqrt{\frac{1}{n} + \frac{(x-\bar{x})^2}{nD_x}}$

г) Построить диаграмму рассеяния признаков x и y . Нанести на диаграмму функцию регрессии $f(x)$, а также нижние и верхние границы линии регрессии $f_{low}(x)$ и $f_{high}(x)$ на уровне значимости $\alpha = 0.1$



д) Построить график остатков $\varepsilon(x) = y - f(x)$



9.1.3. Проверка значимости линейной регрессионной модели

$$H_0 : \beta_1 = 0$$

Статистическая гипотеза – $H' : \beta_1 \neq 0$

а) Указать формулы расчёта показателей, используемых при проверке значимости линейной регрессионной модели

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{\bar{D}_{y x}}{\bar{D}_{y_{ост}}/(n-2)}$	n — объём выборки $(x_1, y_1), \dots, (x_n, y_n)$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(1, n - 2)$	
Формула расчета критической точки	$F_{1-\alpha, 1, n-2}$	

Формула расчета p -value	$1 - F_z(z_{\text{выб}} H_0)$	Правосторонняя критическая область
----------------------------	---------------------------------	------------------------------------

б) Проверить значимость линейной регрессионной модели

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	80.39	0.00	H_0 отклоняется	$\beta_1 \neq 0$
0.05			H_0 отклоняется	$\beta_1 \neq 0$
0.1			H_0 отклоняется	$\beta_1 \neq 0$

9.2 Линейная регрессионная модель общего вида

Факторный признак x – 'B16' Biceps circumference (cm)

Результативный признак y – 'B2' (Percent body fat from Siri's equation)

Уравнение регрессии – квадратичное по x : $f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$

9.2.1. Точечные оценки линейной регрессионной модели

а) Рассчитать точечные оценки параметров линейной регрессионной модели

Параметр	Формула расчета	Значение
β_0	$\tilde{\beta}_0 = (F^T F)^{-1} F^T y_{\downarrow}$, где F — регрессионная матрица, $y_{\downarrow}$ — вектор значений результативного признака.	-12.47
β_1	$\tilde{\beta}_1 = (F^T F)^{-1} F^T y_{\downarrow}$, где F — регрессионная матрица, $y_{\downarrow}$ — вектор значений результативного признака.	0.02
β_2	$\tilde{\beta}_1 = (F^T F)^{-1} F^T y_{\downarrow}$, где F — регрессионная матрица, $y_{\downarrow}$ — вектор значений результативного признака.	0.17

б) Записать точечную оценку уравнения регрессии

$$f(x) = \tilde{\beta}_0 + \tilde{\beta}_1 x + \tilde{\beta}_2 x^2 = -23.47 + 0.02 * x + 0.17 * x^2$$

в) Рассчитать показатели вариации, используемые в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
-------------------	---------------------	------------------------	--------------------

Факторный признак	$\tilde{D}_{Y X} = 26.16$	$k - 1 = 2$	$\frac{n}{k-1} \tilde{D}_{Y X} = 3296.74$
Остаточные признаки	$\tilde{D}_{Y_{ост}} = 43.59$	$n - k = 249$	$\frac{n}{n-k} \tilde{D}_{Y_{ост}} = 44.12$
Все признаки	$\tilde{D}_{Y_{общ}} = 69.76$	$n - 1 = 251$	$\frac{n}{n-1} \tilde{D}_{Y_{общ}} = 70.04$

з) Проверить правило сложения дисперсий

Показатель	$D_{пер}$	$D_{ост}$	$D_{общ}$	$D_{пер} + D_{ост}$
Значение	26.16	43.59	69.76	69.76

д) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Коэффициент детерминации	$R^2 = \frac{\tilde{D}_{Y X}}{\tilde{D}_{Y_{общ}}}$	0.38
Корреляционное отношение	$\tilde{R} = \sqrt{R^2} = \sqrt{\frac{\tilde{D}_{Y X}}{\tilde{D}_{Y_{общ}}}}$	0.61

е) Охарактеризовать тип связи между факторным и результативным признаками, определяемой рассчитанной линейной регрессией

Наблюдается средней силы корреляционная связь между факторным признаком В16 и результативным признаком В2.

Корреляционное отношение $\eta=0.61$ также указывает на наличие выраженной зависимости, но не функциональной зависимости.


9.2.2. Интервальные оценки линейной регрессионной модели

а) Привести формулы расчёта доверительного интервала для значений регрессии $f(x)$


Границы доверительного интервала	Формула расчета
----------------------------------	-----------------

Нижняя граница $f_{low}(x)$	$\tilde{f}(x) - t_{1-\frac{\alpha}{2},(n-k)} \cdot \sqrt{D_{Y_{ост}}^{\text{несмещ}}} \cdot \sqrt{\varphi^{\rightarrow}(x)(F^T F)^{-1} \varphi_{\downarrow}(x)}$
Верхняя граница $f_{high}(x)$	$\tilde{f}(x) + t_{1-\frac{\alpha}{2},(n-k)} \cdot \sqrt{D_{Y_{ост}}^{\text{несмещ}}} \cdot \sqrt{\varphi^{\rightarrow}(x)(F^T F)^{-1} \varphi_{\downarrow}(x)}$

б) Построить диаграмму рассеяния признаков x и y . Нанести на диаграмму функцию регрессии $f(x)$, а также нижние и верхние границы линии регрессии $f_{low}(x)$ и $f_{high}(x)$ на уровне значимости $\alpha = 0.1$



в) Построить график остатков $\varepsilon(x) = y - f(x)$



9.2.3. Проверка значимости линейной регрессионной модели

Статистическая гипотеза – $H_0: \beta_1 = \beta_2 = 0$ $H': \beta_1^2 + \beta_2^2 > 0$

а) Указать формулы расчёта показателей, используемых при проверке значимости линейной регрессионной модели

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{D_{\substack{\text{несмещ} \\ Y X}}}{D_{\substack{\text{несмещ} \\ Y_{\text{ост}}}}}$	n — объём выборки $(x_1, y_1), \dots, (x_n, y_n)$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(k - 1, n - 2)$	
Формула расчета критической точки	$F_{1-\alpha, k-1, n-2}$	

Формула расчета p -value	$1 - F_{z_{\text{выб}} H_0}$	Правосторонняя критическая область
----------------------------	------------------------------	------------------------------------

б) Проверить значимость линейной регрессионной модели

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	74.72	0.00	H_0 отклоняется	$\beta_1^2 + \beta_2^2 > 0$
0.05			H_0 отклоняется	$\beta_1^2 + \beta_2^2 > 0$
0.1			H_0 отклоняется	$\beta_1^2 + \beta_2^2 > 0$

9.3 Множественная линейная регрессионная модель

Факторный признак 1 x_1 – 'B16' Biceps circumference (cm)

Факторный признак 2 x_2 – 'B7' Weight (lbs)

Результативный признак y – 'B2' (Percent body fat from Siri's equation)

Уравнение регрессии – $f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$

а) Рассчитать точечные оценки параметров линейной регрессионной модели

Параметр	Формула расчета	Значение
β_0	$\tilde{\beta}_0 = (F^T F)^{-1} F^T y_{\downarrow}$, где F — регрессионная матрица, $y_{\downarrow}$ — вектор значений результативного признака.	-12.47
β_1	$\tilde{\beta}_1 = (F^T F)^{-1} F^T y_{\downarrow}$, где F — регрессионная матрица, $y_{\downarrow}$ — вектор значений результативного признака.	0.02
β_2	$\tilde{\beta}_2 = (F^T F)^{-1} F^T y_{\downarrow}$, где F — регрессионная матрица, $y_{\downarrow}$ — вектор значений результативного признака.	0.17

б) Записать точечную оценку уравнения регрессии

$f(x) = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \tilde{\beta}_2 x_2 = -12.47 + 0.02x_1 + 0.17x_2$

в) Рассчитать показатели вариации, используемые в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
-------------------	---------------------	------------------------	--------------------

Факторный признак	$\tilde{D}_{Y X_1, X_2} = 26.16$	$k - 1 = 2$	$\frac{n}{k-1} \tilde{D}_{Y X_1, X_2} = 3296.74$
Остаточные признаки	$\tilde{D}_{Y_{ост}} = 43.59$	$n - k = 249$	$\frac{n}{n-k} \tilde{D}_{Y_{ост}} = 44.12$
Все признаки	$\tilde{D}_{Y_{общ}} = 69.76$	$n - 1 = 251$	$\frac{n}{n-1} \tilde{D}_{Y_{общ}} = 70.04$

г) Проверить правило сложения дисперсий

Показатель	$D_{незн}$	$D_{ост}$	$D_{общ}$	$D_{незн} + D_{ост}$
Значение	26.16	43.59	69.76	69.76

д) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Множественный коэффициент детерминации	$R^2 = \frac{\tilde{D}_{Y X_1, X_2}}{\tilde{D}_{Y_{общ}}}$	0.38
Множественное корреляционное отношение	$\tilde{R} = \sqrt{R^2} = \sqrt{\frac{\tilde{D}_{Y X_1, X_2}}{\tilde{D}_{Y_{общ}}}}$	0.61

е) Охарактеризовать тип связи между факторным и результативным признаками, определяемой рассчитанной линейной регрессией

Наблюдается средней силы корреляционная связь между факторным признаком В16 ,В7 и результативным признаком В2.

9.4. Выводы

а) Сводная таблица показателей вариации для различных регрессионных моделей

Источник вариации	Простейшая линейная модель	Линейная модель с квадратичным членом	Множественная линейная модель
-------------------	----------------------------	---------------------------------------	-------------------------------

Факторный признак	$\tilde{D}_{Y X} = 16.97$	$\tilde{D}_{Y X} = 26.16$	$\tilde{D}_{Y X_1, X_2} = 26.16$
Остаточные признаки	$\tilde{D}_{Y_{ост}} = 52.78$	$\tilde{D}_{Y_{ост}} = 43.59$	$\tilde{D}_{Y_{ост}} = 43.59$
Все признаки	$\tilde{D}_{Y_{общ}} = 69.76$	$\tilde{D}_{Y_{общ}} = 69.76$	$\tilde{D}_{Y_{общ}} = 69.76$

б) Сводная таблица свойств различных регрессионных моделей

Свойство	Простейшая линейная модель	Линейная модель с квадратичным членом	Множественная линейная модель
Точность	неточная	неточная	неточная
Значимость	Значимая	Значимая	Значимая
Адекватность	Адекватная	Адекватная	Адекватная
Степень тесноты связи	слабая	умеренная	умеренная

Вывод (в терминах предметной области)

В результате проведённого в п.9 статистического анализа обнаружено, что результативный признак В16 имеет средней силы связь с факторным признаком В2. При добавлении в модель факторного признака В7 связь между результативным признаком и факторными признаками не ухудшилась.